

Отчет MyReport_Striukova.

1. В чем состоит задача и какие данные были проанализированы.

В банке «ЦифраФинанс» уровень дефолта превышает плановые уровни по ряду регионов и каналов, что негативно сказывается на резервах. Нужно разобраться в причинах, проверить качество данных и предложить конкретные изменения кредитной политики.

Был проанализирован розничный кредитный портфель банка «ЦифраФинанс» за период 2023-2024 гг.: 5 регионов, 3 канала привлечения и 4 продукта.

Задачи:

1. Проверить качество данных и произвести их очистку;
2. Описать бизнес-процесс кредитования;
3. Проанализировать портфель. Выявить факторы дефолта, проверить интеракции, разделить заемщиков на группы риска, посчитать кредитный доход и ожидаемые потери;
4. Произвести сравнение плановых и фактических показателей KPI на уровне «регион-канал»;
5. Предложить изменения кредитной политики с числовой оценкой эффекта;
6. Проверить черновик отчета стажера на различного рода ошибки;
7. Построить дашборд для еженедельного мониторинга портфеля.

2. Подход к решению: методы, допущения, инструменты.

Работа была выстроена следующим образом: работа с данными, поиск причин дефолта, денежная оценка рисков и доходности, выработка рекомендаций.

Очистка данных:

В первую очередь были удалены дубликаты. Проверки на некорректные даты и пропуски ничего не выявили. Важно, что строки с пропущенными данными о доходе и занятости выделяла в качестве ошибки, так как в рамках кейса нет возможности уточнить корректные значения. (На практике я бы вернула это в соответствующий отдел для корректировки данных.)

Флаг дефолта сверила с правилом «дефолт – просрочка в 90+ дней», проверила отрицательный DPD (расхождений нет, проверка прошла без исправлений).

Выбросы не были удалены, пошла другим путем. Ограничила значения 1-м и 99-м процентилями. Таким образом был сохранен целый сегмент (например: крупные кредиты, рискованные заемщики), который важен для анализа.

После деньги были приведены в естественный банковский вид. Деньги округлила до копеек, скоринг и возраст до целых чисел.

Методы

анализа:

1. Описательная статистика. Просмотр дефолтности по регионам, каналам, продуктам, занятости, возрасту и кварталам выдачи отразил, где сосредоточены проблемы;

- 2. T-test (тест Стьюдента). Связь каждого признака с дефолтом, выявляла является ли это случайностью или закономерностью. Применялось на числовых данных (доход, скоринг);
- 3. χ^2 -тест. Для выявления связи каждого признака с дефолтом, использовала для категориальных переменных (канал, регион);
- 4. Логистическая регрессия. Методы 2 и 3 отражают каждый фактор по отдельности, регрессия учитывает все факторы одновременно, что дает понимание того, какие из них работают независимо от остальных;
- 5. Сегментация. Разделение заемщиков на 3 группы риска по скорингу и DTI;
- 6. Расчет EL и процентного дохода. Подсчет потерь по формуле $EL = PD \times EAD \times LGD$, а процентный доход только по кредитам без дефолта (дефолтный кредит прибыли банку не приносит);
- 7. План-факт анализ. Применялся для сравнения факта с планом на уровне «регион-канал»;
- 8. Оценка рекомендаций через break-even фильтр. Оценка рекомендаций через деньги. Если убыток превышает ожидаемый доход банка – клиент отклоняется.

Допущения:

LGD – 45%, так как дефолт не равен потере всей суммы;
EAD = сумме кредита, по причине отсутствие графика погашения в исходных данных;
Процентный доход только по недефолтным кредитам (при дефолте все проценты теряются).
План с фактом сравниваю только там, где присутствует эта возможность (для 8 из 15 комбинаций отсутствует (ограничение анализа).
Перед сравнением объединила branch_reference.csv (далее именуется как справочник) до уровня «регион-канал», во избежание дублей.

3. Ключевые результаты по всем данным с визуализацией.


Отчет об очистке:

Количество строк в исходном датасете – 6031;
Количество выявленных проблемных значений или записей – 503 (43 записи-дубликата и 460 экстремальных значения);
Количество строк после очистки – 5988;
Количество исправленных, заполненных, удаленных значений – 503 (43 записи удалены, 460 исправлено, 0 заполненных).

cleaning_log_Striukova					
№	Ошибка	Столбец с ошибкой	Количество случаев	Действие	Обоснование действия
1	Повторные loan_id	loan_id	43	Удалены	Оставили первое вхождение договора
2	Строки с незаполненными полями	все столбцы	0	Проверка пройдена	Пропусков в датасете нет
3	Нечитаемый формат issue_date	issue_date	0	Проверка пройдена	Все даты читаются корректно
4	Выдачи вне периода 2023–2024	issue_date	0	Проверка пройдена	Все выдачи внутри целевого окна
5	Значения region вне справочника	region	0	Проверка пройдена	Значения соответствуют справочнику
6	Значения channel вне справочника	channel	0	Проверка пройдена	Значения соответствуют справочнику
7	Значения loan_product вне справочника	loan_product	0	Проверка пройдена	Значения соответствуют справочнику
8	Расхождение DPD и is_default	days_past_due, is_default	0	Проверка пройдена	Флаг дефолта согласован с глубиной просрочки
9	Отрицательный days_past_due	days_past_due	0	Проверка пройдена	—
10	Возраст вне диапазона 18–80	age	0	Проверка пройдена	—
11	Доход <= 0	monthly_income	0	Проверка пройдена	—
12	Экстремальные значения: monthly_income	monthly_income	120	Ограничение перцентилем 1-99	Хвосты подтянуты до перцентилей, строки сохранены
13	Экстремальные значения: loan_amount	loan_amount	103	Ограничение перцентилем 1-99	Хвосты подтянуты до перцентилей, строки сохранены
14	Экстремальные значения: monthly_payment	monthly_payment	120	Ограничение перцентилем 1-99	Хвосты подтянуты до перцентилей, строки сохранены
15	Экстремальные значения: credit_score	credit_score	117	Ограничение перцентилем 1-99	Хвосты подтянуты до перцентилей, строки сохранены

Описательная статистика портфеля:

Фактический уровень дефолтов в два раза выше целевого.




Факторы дефолта:

Проверка связи признаков и дефолтов.

Числовые признаки проверяла через t-тест, категориальные через χ^2 -тест.



Сильнейшим предиктором дефолта является DTI (коэффициент +0,925), вторым по силе стал скоринговый балл (-0,852). Остальные признаки значительно слабее (сумма кредита, доход и возраст). Отмечу, что связь суммы кредита с дефолтом слабая и отрицательная (коэффициент -0,148).



Интеракция региона и канала:


Проверка интеракции показала, что канал влияет на дефолтность (χ^2 , $p = 0,008$), а регион нет (χ^2 , $p = 0,40$). Партнерский канал дает наибольшую PD во всех регионах (20,4–24,3% против 17,1–23,0% у branch и online), причем однородно - значимой интеракции не выявлено.

Следовательно, избыточный риск связан с партнерским каналом в целом, а не с конкретными регионами или связками.



Сегментация:


Разделение клиентов на группы риска по скорингу и DTI.



Различия между сегментами статистически значимы (χ^2 - тест, $p < 0,001$). Показатель дефолта растет LOW – MED – HIGH. Отсюда можно сделать вывод, что сегментация может служить основой кредитной политики.

Доходность и ожидаемые потери:


Сегмент HIGH несет потери сопоставимы с процентным доходом банка, являясь самой ненадежной частью портфеля.



План-факт анализ:

На данном этапе были сопоставлены фактические показатели с планами из справочника на уровне «регион-канал». Информация в данном источнике покрывает лишь 7 из 15 комбинаций (по 8 планы отсутствуют). Это ограничение анализа.

Выводы по 7 комбинациям. Дефолтность выше плана (факт – 17.8–20.4%, план 9-16%), скоринговый балл выше плана (+18,9...+41,7 п.), DTI выше плана (+1,9...+8,9 п.п.). Следовательно, текущая скоринговая модель не защищает банк.




Аудит отчета Стажеркина:

analyst_report_marks		
Цитата ошибки	Тип ошибки	Правильный вывод или расчет
Я посчитал, что уровень дефолтов составляет 12,3%, что НИЖЕ целевого показателя в 10%. Считал так: взял сумму колонки is_default и поделил на 100.	Фактическая и логическая	PD = sum(is_default) / число строк = 1199 / 5988 = 20,02%, а не 12,3%: деление на 100 бессмысленно. 12,3% ВЫШЕ целевых 10%, а не ниже.
Дефолт — это любая просрочка. Поэтому я считал дефолты как все строки, где days_past_due > 0. Получилось 28% дефолтов.	Методологическая	По условию кейса дефолт = просрочка 90+ дней. Корректная PD = 20,02%. В значение 28% включены технические просрочки 1–89 дней. Неверное определение искажает все последующие метрики (PD, EL, сегментацию).
Я рассчитал корреляцию loan_amount с is_default и получил r = 0,71 (сильная положительная). Вывод: большие кредиты нужно выдавать осторожнее.	Фактическая	Указанная связь в данных отсутствует. Стандартизованный коэффициент логистической регрессии по loan_amount равен -0,148 (слабая отрицательная связь). Значение r = 0,71 противоречит данным портфеля; вывод не подтвержден.
Связь DTI с дефолтом незначима (p = 0,28), поэтому DTI не стоит использовать как критерий одобрения.	Фактическая и методологическая	DTI — сильнейший предиктор дефолта в портфеле: стандартизованный коэффициент +0,925 (максимальный по модулю). PD сегмента HIGH составляет 37,43% против 2,15% у сегмента LOW. Исключение DTI из критериев одобрения лишает банк основного фильтра риска.
Рекомендую ЗАКРЫТЬ партнерский канал в Южных регионах полностью, так как он убыточен.	Логическая (нарушение бизнес-ограничения кейса)	Закрытие South + partner запрещено ограничением кейса — для этой комбинации допустимо только ужесточение условий. Фактический DR South+partner = 20,4% при плане 16%. Корректное действие: точечное ужесточение порогов одобрения.
При расчете Expected Loss принял LGD = 100%, так как при дефолте банк теряет всю сумму кредита.	Методологическая	Принято LGD = 45% (отраслевое допущение для необеспеченной розницы с учетом частичного возмещения через взыскание). При LGD = 100% EL завышен в 2,2 раза: например, EL сегмента HIGH составляет 194,85 млн руб. При LGD = 45% и около 433 млн руб. при LGD = 100%.
Для проверки статистической значимости я использовал t-тест для всех переменных, включая тип занятости и канал (channel, region).	Методологическая	Категориальные переменные это χ^2 -тест по таблице сопряженности: channel p = 0,008 (связь присутствует), region p = 0,402 (отсутствует). t-тест по категориальным переменным невалиден.
Распределение нормальное, поэтому среднее хорошо его описывает и выбросы не влияют на анализ.	Фактическая и методологическая	Распределение дохода правосторонне скошено: среднее = 79 494 руб. > медианы = 77 107 руб. Выбросы потребовали ограничения по перцентилим. При скошенном распределении среднее искажено — нужна медиана. Значение 74 500 руб. получено на сырых данных без очистки.

Для более детального изучения смотреть файл analyst_report_marks.csv.

Дашборд:
Для еженедельного мониторинга был собран интерактивный дашборд.
Публичная ссылка:



4. Выводы и рекомендации с числовым обоснованием.

Выводы:

- Проблема дефолтности системы. Фактический уровень дефолтов 20,02%, примерно вдвое выше плановых ориентиров. Планы в справочнике 9–16% (в среднем $\approx 10,7\%$). Превышение во всех отслеживаемых сегментах.
- Скоринговая модель не защищает банк. Скоринг выше плана при дефолтности вдвое выше плана, это означает, что модель присваивает высокие баллы клиентам, которые не платят.
- Закредитованность клиентов – главная причина потерь. Банк выдавал кредиты тем, у кого и так высокая долговая нагрузка. DTI – сильнейший предвестник дефолта (коэффициент 0,93), его фактическое значение выше плана во всех сегментах.
- Высокий риск сегмента HIGH. На данный сегмент приходит основная доля ожидаемых потерь при дефолтном показателе 37,43%. Потери сопоставимы с процентным доходом.
- Избыточный риск связан с партнерским каналом в целом, а не с отдельными регионами. Partner дает наибольшую PD в каждом регионе (20,4–24,3% против 17,1–23,0% у branch и online), а регион не значим (χ^2 , $p = 0,40$).

Рекомендации:

Экономический принцип прибыльной сделки заключается в том, что банку следует отказать клиенту только в том случае, если ожидаемый убыток по заявке превышает ожидаемый процентный доход. Ожидаемый убыток оценивается как прогнозная вероятность дефолта $\times$ ожидаемая сумма кредита $\times$ LGD, ожидаемый доход, если клиент платит исправно - $(1 - \text{вероятность дефолта}) \times \text{процентный доход}$.

№	Рекомендация	Отклонено кредитов	Избежано дефолтов	Hit-rate, %	Экономия EL, млн руб.	Потеря дохода, млн руб.	Чистый эффект, млн руб.
1	HIGH: DTI>70% и score<640	610	413	67.7	91.9	17.1	74.8
2	car: score<600 или DTI>75%	480	342	71.2	73.0	12.6	60.3
3	partner: score<600	345	234	67.8	32.9	5.4	27.5
4	age<25 и DTI>65%	183	140	76.5	22.1	2.5	19.6
5	South+partner: DTI>70%	22	14	63.6	2.8	0.6	2.1
	ИТОГО (уникальные кредиты)	960	662	69.0	114.5	20.4	94.1

В сумме правила затрагивают 960 уникальные заявки и дают чистый ожидаемый эффект +94,1 млн руб.

1. Пересмотреть скоринговые пороги и добавить фильтры одобрения.
2. DTI как жесткий критерий одобрения. Долговая нагрузка основная причина дефолтов.
3. Дополнить справочник планами по 8 комбинациям «регион-канал». При отсутствии планов невозможен контроль данных сегментов.
4. Внедрить еженедельный мониторинг, используя дашборд. Поможет отследить дефолтность, DTI и план-факт в динамике.

5. Приложения: код, расчеты, дополнительные таблицы.

1. Корректное определение дефолта в неочищенных данных является одним из самых главных правил кейса.

```
# источник истины – DPD, флаг пересчитываем от него
df.loc[df['days_past_due'] >= 90, 'is_default'] = 1
df.loc[df['days_past_due'] < 90, 'is_default'] = 0
```

2. Определение процентного дохода от не-дефолтных кредитов и расчет EL по риск-сегментам.

```
# процентный доход
df['interest_income'] = np.where(
    df['is_default'] == 0,
    df['monthly_payment'] * df['loan_term_months'] - df['loan_amount'],
    0 # дефолт – теряем проценты (консервативно)
)

# EL по сегментам
el = df.groupby('risk_segment').agg(
    loans=('loan_id', 'count'),
    PD=('is_default', 'mean'),
    EAD=('loan_amount', 'sum'),
    interest_income=('interest_income', 'sum')
).reset_index()

el['EL'] = (el['PD'] * el['EAD'] * LGD).round(0)
el['net_result'] = el['interest_income'] - el['EL']
el['net_result_per_loan'] = (el['net_result'] / el['loans']).round(0)
```


3. План-факт: агрегация справочника до «регион-канал» + inner join

```
branch_ref = pd.read_csv('branch_reference.csv')

# план по region × channel
ref_agg = branch_ref.groupby(['region', 'channel']).agg(
    plan_default_rate=('target_default_rate', 'mean'),
    plan_credit_score=('target_avg_credit_score', 'mean'),
    plan_dti=('target_avg_dti', 'mean')
).round(3).reset_index()

# факт
fact = df.groupby(['region', 'channel']).agg(
    fact_loans=('loan_id', 'count'),
    fact_pd=('is_default', 'mean'),
    fact_score=('credit_score', 'mean'),
    fact_dti=('dti_ratio', 'mean')
).round(3).reset_index()

# join — только те сегменты где есть план
pf = fact.merge(ref_agg, on=['region', 'channel'], how='inner')
```

4. Прогноз индивидуального PD для каждого клиента

```
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
import warnings
warnings.filterwarnings('ignore')

# Обучаем модель на числовых + категориальных признаках
num_cols = ['age', 'monthly_income', 'loan_amount', 'interest_rate',
            'credit_score', 'dti_ratio', 'loan_term_months',
            'work_experience_years', 'existing_loans_count']
cat_cols = ['region', 'channel', 'loan_product', 'employment_type']

X_num = df[num_cols].copy()
X_cat = pd.get_dummies(df[cat_cols], drop_first=True, dtype=int)
X = pd.concat([X_num, X_cat], axis=1)
y = df['is_default']

# Запоминаем порядок признаков, чтобы потом применить ко всему df
feature_names = X.columns

scaler = StandardScaler()
X_scaled = pd.DataFrame(scaler.fit_transform(X), columns=feature_names)

model = LogisticRegression(max_iter=1000, random_state=42)
model.fit(X_scaled, y)

# Прогноз вероятности дефолта для КАЖДОГО клиента
df['pred_pd'] = model.predict_proba(X_scaled)[:, 1]

# Ожидаемый EL и ожидаемый доход по каждому клиенту
df['exp_el'] = df['pred_pd'] * df['loan_amount'] * LGD
df['exp_income'] = (1 - df['pred_pd']) * df['interest_income']

# Клиент убыточен, если ожидаемый убыток > ожидаемого дохода
df['is_unprofitable'] = (df['exp_el'] > df['exp_income']).astype(int)

# Экономический cutoff: отклонение прибыльно, только если ожидаемый убыток
# клиента превышает его ожидаемый доход. "Прибыльный" риск банк не режет.
df['profitable_to_reject'] = (df['exp_el'] > df['exp_income']).astype(int)

print(f"Доля клиентов, которых выгодно отклонить: {df['profitable_to_reject'].mean()*100:.2f}%")
print(f"Доля 'убыточных' клиентов по прогнозу: {df['is_unprofitable'].mean()*100:.2f}%")
print(f"Средняя прогнозная PD: {df['pred_pd'].mean()*100:.2f}%")
```

С самым главным break-even фильтром

```
# Ожидаемый EL и ожидаемый доход по каждому клиенту
df['exp_el'] = df['pred_pd'] * df['loan_amount'] * LGD
df['exp_income'] = (1 - df['pred_pd']) * df['interest_income']
```

Расчет рекомендаций на основе подготовленной ранее модели

```
all_recommendations = []

# 1. Токсичное ядро HIGH-сегмента
mask_1 = (df['risk_segment'] == 'HIGH') & (df['dti_ratio'] > 70) & \
        (df['credit_score'] < 640) & (df['profitable_to_reject'] == 1)
all_recommendations.append(evaluate_recommendation(mask_1, "HIGH: DTI>70% и score<640"))

# 2. Партнерский канал: отсекаем низкий хвост скоринга
mask_2 = (df['channel'] == 'partner') & (df['credit_score'] < 600) & \
        (df['profitable_to_reject'] == 1)
all_recommendations.append(evaluate_recommendation(mask_2, "partner: score<600"))

# 3. South + partner: ужесточение без закрытия канала (правило кейса)
mask_3 = (df['region'] == 'South') & (df['channel'] == 'partner') & \
        (df['dti_ratio'] > 70) & (df['profitable_to_reject'] == 1)
all_recommendations.append(evaluate_recommendation(mask_3, "South+partner: DTI>70%"))

# 4. Автокредиты: низкий скоринг или экстремальная нагрузка
mask_4 = (df['loan_product'] == 'car') & \
        ((df['credit_score'] < 600) | (df['dti_ratio'] > 75)) & \
        (df['profitable_to_reject'] == 1)
all_recommendations.append(evaluate_recommendation(mask_4, "car: score<600 или DTI>75%"))

# 5. Молодые клиенты с критичным DTI
mask_5 = (df['age'] < 25) & (df['dti_ratio'] > 65) & (df['profitable_to_reject'] == 1)
all_recommendations.append(evaluate_recommendation(mask_5, "age<25 и DTI>65%"))
```

Полный код этапов 1-5 можно увидеть в файле MyCode_Striukova.ipynb, а список зависимостей – requirments.txt

Примеры расчетов.

Формула расчета процентного дохода по кредиту:

$\text{interest_income} = \text{monthly_payment} \times \text{loan_term_months} - \text{loan_amount}$. Признается только для случаев, когда $\text{is_default} = 0$

Пример:

- Ежемесячный платеж: 13 706 руб.
- Срок кредита: 36 месяцев
- Сумма кредита: 400 000 руб.

$\text{interest_income} = 13\,706 \times 36 - 400\,000 = 493\,416 - 400\,000 = 93\,416$ руб.

Для дефолтного кредита ($\text{is_default} = 1$) с теми же параметрами: $\text{interest_income} = 0$ руб.

Формула расчета Expected Loss сегмента:

$EL = PD \times EAD \times LGD$, где PD — доля дефолтов в сегменте, EAD — сумма выданных кредитов, LGD = 45% (допущение).

Пример для HIGH-сегмента:

- PD = 37,4% (доля дефолтов HIGH)
- EAD = 613 млн руб. (сумма кредитов сегмента)
- LGD = 45%

$EL = 0,374 \times 613\,000\,000 \times 0,45 = 103,0$ млн руб.

Процентный доход сегмента HIGH = 114,5 млн руб., чистый результат сегмента:
 $114,5 - 103,0 = +11,5$ млн руб.

Эффект рекомендации.

Формула: $net_effect = EL_saved - income_lost$, где $EL_saved = \sum (PD_i \times loan_amount_i \times LGD)$ по отклоненным клиентам, $income_lost = \sum ((1 - PD_i) \times interest_income_i)$ по тем же клиентам.

Пример для рекомендации 1 (HIGH-сегмент: DTI > 70% и score < 640):

- отклоняем 610 кредитов
- среди них 413 фактических дефолтов (hit-rate 67,7%)
- ожидаемая экономия EL = 91,9 млн руб.
- потеря процентного дохода = 17,1 млн руб.

$net_effect = 91,9 - 17,1 = +74,8$ млн руб.

Совокупный эффект всех 5 рекомендаций (с учётом пересечений):

- уникальных отклоняемых кредитов: 960 (16% портфеля)
- избегаем 662 реальных дефолта (hit-rate 69,0%)
- экономия EL: 114,5 млн руб.
- потеря дохода: 20,4 млн руб.

$net_effect_итого = 114,5 - 20,4 = +94,1$ млн руб.

Отклонения план-факта:

Формулы:

- $dev_pd = fact_pd - plan_pd$ (для PD: отрицательное отклонение = хорошо)
- $dev_score = fact_score - plan_score$ (положительное = хорошо)
- $dev_dti = fact_dti - plan_dti$ (отрицательное = плохо)

Пример для Moscow/branch:

- $fact_pd = 18,2\%$, $plan_pd = 9,0\% \rightarrow dev_pd = +9,2$ п.п. (BAD — факт хуже плана)
- $fact_score = 642$, $plan_score = 623 \rightarrow dev_score = +19$ п. (OK — скоринг выше плана)
- $fact_dti = 56,4\%$, $plan_dti = 47,5\% \rightarrow dev_dti = +8,9$ п.п. (BAD — DTI выше плана)

Парадокс «скоринг выше плана при дефолтности вдвое выше плана» означает, что скоринговая модель мискалибрована: клиенты формально лучше плановых, но дефолтуют вдвое чаще.

Дополнительные таблицы

Бизнес-процессы:

Шаг процесса	Входные данные	Исполнители	Выходной результат
Привлечение клиента	Канал (branch / online / partner), регион, продукт (consumer / car / renovation / education)	Маркетинг / Продажи	Заявка клиента
Сбор данных по клиенту	Заявка, анкета (возраст, доход, занятость, стаж), данные бюро (credit_score, DTI)	Андеррайтинг / Скоринг	Профиль клиента и параметры кредита
Первичный скоринг	credit_score, dti_ratio, monthly_income, employment_type	Риск-менеджмент	Решение: одобрить / отклонить / ручной андеррайтинг
Андеррайтинг и назначение условий	Скоринговый результат, loan_amount, loan_term_months, interest_rate	Андеррайтинг	Одобренные условия кредита
Выдача кредита	Одобренная заявка	Операционный блок	Активный кредит (loan_amount, issue_date, monthly_payment)
Мониторинг портфеля	Платежная дисциплина клиента	Риск-мониторинг / Collection	Статус кредита: current / overdue / default
Работа с просроченной задолженностью	days_past_due	Collection / Проблемная задолженность	Дефолт is_default = 1 при DPD >= 90
Оценка доходности и рисков	loan_portfolio_clean, branch_reference	Финансы / Бизнес-анализ / Риск	Отчет по доходности, EL, план-факту

План-факт:

region	channel	fact_loans	fact_pd	fact_score	fact_dti	plan_default_rate	plan_credit_score	plan_dti	dev_pd	dev_score	dev_dti	pd_status	score_status	dti_status
Moscow	branch	636	0.182	641.936	56.386	0.09	623.0	47.5	0.092	18.9	8.9	BAD	OK	BAD
Moscow	online	690	0.203	642.939	58.23	0.1	622.0	52.7	0.103	20.9	5.5	BAD	OK	BAD
SPb	branch	443	0.178	639.867	53.64	0.1	612.0	50.4	0.078	27.9	3.2	BAD	OK	BAD
SPb	online	450	0.191	637.78	56.517	0.09	616.0	53.0	0.101	21.8	3.5	BAD	OK	BAD
Siberia	branch	320	0.188	615.462	54.482	0.12	594.0	51.6	0.068	21.5	2.9	BAD	OK	BAD
South	partner	211	0.204	618.678	56.623	0.16	577.0	54.7	0.044	41.7	1.9	BAD	OK	BAD
Ural	branch	419	0.196	624.809	53.984	0.09	601.0	48.8	0.106	23.8	5.2	BAD	OK	BAD

Итог рекомендаций:

№	Рекомендация	Отклонено кредитов	Избежано дефолтов	Hit-rate, %	Экономия EL, млн руб.	Потеря дохода, млн руб.	Чистый эффект, млн руб.
1	HIGH: DTI>70% и score<640	610	413	67.7	91.9	17.1	74.8
2	car: score<600 или DTI>75%	480	342	71.2	73.0	12.6	60.3
3	partner: score<600	345	234	67.8	32.9	5.4	27.5
4	age<25 и DTI>65%	183	140	76.5	22.1	2.5	19.6
5	South+partner: DTI>70%	22	14	63.6	2.8	0.6	2.1
ИТОГО (уникальные кредиты)		960	662	69.0	114.5	20.4	94.1

Со всеми приложениями можно ознакомиться в соответствующих файлах.